
Università degli Studi Milano-Bicocca
Corso di Laurea Magistrale in Matematica



Numerical Linear Algebra

Gabriele Vergari

Anno Accademico 2025/2026

Indice

1	Introduzione	2
2	Il metodo di Rayleigh–Ritz	3
2.1	Proiezione di un operatore su un sottospazio	3
2.2	Ritz values e Ritz vectors	3
2.3	Ottimalità variazionale	3
2.4	La scelta di $\mathcal{S}$ e i Sottospazi di Krylov	4
3	Sottospazi di Krylov	4
3.1	Definizione e legame polinomiale	4
3.2	Interpretazione spettrale e ottimalità polinomiale	5
3.3	Rayleigh–Ritz applicato ai sottospazi di Krylov	5
4	L’algoritmo di Lanczos	6
4.1	Dalla proiezione di Rayleigh–Ritz alla costruzione di una base	6
4.2	Ricorrenza a tre termini	6
4.3	La Decomposizione di Lanczos	6
4.4	Coppie di Ritz	7
5	Accuratezza delle approssimazioni nel metodo di Lanczos	7
5.1	Residui e qualità delle coppie di Ritz	7
5.2	Accuratezza degli autovettori: il teorema di Davis–Kahan	8
5.3	Analisi a priori della convergenza: i bound di Kaniel–Paige–Saad	9
6	Aspetti numerici del metodo di Lanczos	10
6.1	Perdita di ortogonalità in aritmetica finita	10
6.2	Quantificazione della perdita di ortogonalità	11
6.2.1	Strategie di re-ortogonalizzazione	11
6.3	La trasformazione shift-and-invert	11
6.3.1	Aspetti implementativi	12
7	Esperimenti numerici	13
7.1	Impostazione dei test	13
7.2	Esperimento 1: convergenza degli autovalori estremi vs. interni	13
7.3	Esperimento 2: shift-and-invert per autovalori interni	15
7.4	Esperimento 3: ghost eigenvalues e perdita di ortogonalità	17
7.5	Esperimento 4: Lanczos standard vs. Full Re-Orthogonalization	19
7.6	Esperimento 5: Selective Orthogonalization	21
7.7	Esperimento 6a: bound di Kaniel–Paige–Saad	23
7.8	Esperimento 6b: autovettori e teorema di Davis–Kahan	24
8	Discussione finale e conclusioni	25

1 Introduzione

Il calcolo degli autovalori di matrici di grandi dimensioni è un pilastro computazionale in ambiti quali la discretizzazione di equazioni alle derivate parziali (PDE), l'analisi modale e la riduzione dell'ordine dei modelli (MOR). In molti di questi contesti, la matrice $A \in \mathbb{R}^{n \times n}$ è simmetrica e l'analisi non richiede la conoscenza dell'intero spettro, ma si focalizza su una piccola porzione di esso, tipicamente gli autovalori estremi.

Questa esigenza è dettata dalla natura fisica dei problemi trattati: ad esempio, nella discretizzazione di equazioni ellittiche come il problema di Poisson o nell'analisi degli stati stazionari dell'equazione di Schrödinger discreta, sono gli autovalori di modulo minimo a codificare le proprietà fisiche fondamentali del sistema — le frequenze proprie di oscillazione o i livelli energetici dello stato fondamentale. Analogamente, nello studio della stabilità di schemi numerici per equazioni paraboliche (come l'equazione del calore), è il raggio spettrale $\rho(A)$ del propagatore discreto a governare la velocità di convergenza verso lo stato stazionario. Di conseguenza, il calcolo della totalità degli n autovalori risulterebbe non solo oneroso, ma privo di rilevanza rispetto agli obiettivi della modellazione.

Per matrici grandi e sparse, i metodi diretti basati su fattorizzazioni complete (come la decomposizione QR o l'algoritmo di Householder) risultano impraticabili: il costo computazionale $O(n^3)$ e il fenomeno del *fill-in* saturano rapidamente le risorse di memoria. Si ricorre pertanto a metodi iterativi di proiezione, che operano applicando ripetutamente l'operatore lineare — sia tramite prodotti matrice-vettore che mediante la risoluzione di sistemi lineari sparsi nel caso di tecniche *shift-and-invert* — per costruire approssimazioni dello spettro in sottospazi di dimensione ridotta $m \ll n$.

Il **metodo di Lanczos** rappresenta l'algoritmo d'elezione per il caso simmetrico. Esso coniuga l'efficacia della proiezione di Rayleigh–Ritz con la struttura dei **sottospazi di Krylov**. La simmetria di A permette di generare una base ortonormale del sottospazio mediante una **ricorrenza a tre termini**, riducendo drasticamente il costo per iterazione e l'occupazione di memoria rispetto a metodi per matrici generali (come l'algoritmo di Arnoldi). Tuttavia, l'efficienza teorica si scontra con i limiti dell'aritmetica finita: la perdita progressiva di ortogonalità tra i vettori della base introduce instabilità numeriche, come la comparsa di autovalori spuri (*ghost eigenvalues*), che costituiscono uno dei temi centrali di questa relazione.

2 Il metodo di Rayleigh–Ritz

2.1 Proiezione di un operatore su un sottospazio

Sia $A \in \mathbb{R}^{n \times n}$ una matrice simmetrica e sia $\mathcal{S} \subseteq \mathbb{R}^n$ un sottospazio di dimensione m . Fissata una base ortonormale $\{q_1, \dots, q_m\}$ per $\mathcal{S}$, sia $Q = [q_1, \dots, q_m] \in \mathbb{R}^{n \times m}$ la matrice avente tali vettori come colonne, tale che $Q^T Q = I_m$. Si definisce *matrice di Rayleigh* di A rispetto a $\mathcal{S}$ la matrice:

$$H = Q^T A Q \in \mathbb{R}^{m \times m}. \quad (1)$$

Essa rappresenta, rispetto alla base Q , la restrizione ad $\mathcal{S}$ dell'operatore proiettato $\Pi_{\mathcal{S}} A$, dove $\Pi_{\mathcal{S}} = Q Q^T$ è il proiettore ortogonale su $\mathcal{S}$. La simmetria di A garantisce banalmente quella di H .

Un sottospazio $\mathcal{S}$ si dice *invariante* per A se $A\mathcal{S} \subseteq \mathcal{S}$. Tale condizione equivale a richiedere che la *matrice residua*

$$R = A Q - Q H \quad (2)$$

sia identicamente nulla. Infatti, sostituendo H , si ottiene $R = A Q - Q Q^T A Q = (I_n - \Pi_{\mathcal{S}}) A Q$; pertanto $R = 0$ se e solo se l'immagine di Q tramite A è interamente contenuta in $\mathcal{S}$. Se $\mathcal{S}$ è invariante, data un'autocoppia (θ, x) di H (ossia $Hx = \theta x$), si ottiene $A Q x = Q H x = \theta Q x$; ne consegue che (θ, Qx) è un'autocoppia di A . Ciò dimostra l'inclusione: $\sigma(H) \subseteq \sigma(A)$.

Il metodo di Rayleigh–Ritz approssima il problema spettrale per A estraendo le soluzioni dal problema ridotto associato ad H . Le autocoppie approssimate, dette *coppie di Ritz* $(\theta_i, y_i = Qx_i)$, forniscono stime ottimali subordinate al sottospazio $\mathcal{S}$.

2.2 Ritz values e Ritz vectors

Gli autovalori $\theta_1, \dots, \theta_m$ della matrice proiettata H sono detti *Ritz values* e costituiscono le approssimazioni degli autovalori di A nel sottospazio $\mathcal{S}$. I corrispondenti vettori

$$y_i = Q g_i, \quad i = 1, \dots, m, \quad (3)$$

ottenuti per espansione degli autovettori g_i di H nella base Q , prendono il nome di *Ritz vectors*. Per valutare la precisione dell'approssimazione fornita dalla coppia (θ_i, y_i) , si definisce il vettore residuo $r_i = A y_i - \theta_i y_i$.

L'accuratezza della stima viene quantificata mediante la norma euclidea del residuo $\|r_i\|_2$. Tale scelta trova fondamento teorico nel Teorema di Bauer–Fike, il quale stabilisce una relazione tra il residuo e la distanza spettrale. Per matrici normali (e dunque simmetriche), la base degli autovettori è ortonormale, il che implica un numero di condizionamento spettrale unitario ($\kappa_2(V) = 1$).

Sotto queste ipotesi, per ogni *Ritz value* θ_i esiste almeno un autovalore $\lambda \in \sigma(A)$ tale che:

$$|\lambda - \theta_i| \leq \frac{\|r_i\|_2}{\|y_i\|_2}. \quad (4)$$

Imponendo la condizione di normalizzazione $\|y_i\|_2 = 1$, la norma del residuo fornisce un limite superiore rigoroso all'errore di approssimazione. Pertanto, il monitoraggio di $\|r_i\|_2$ costituisce un criterio di arresto robusto, garantendo la convergenza numerica della soluzione verso lo spettro dell'operatore originale.

2.3 Ottimalità variazionale

I Ritz values godono di un'importante proprietà di ottimalità: sono le migliori approssimazioni agli autovalori di A ottenibili da $\mathcal{S}$. Non è garantito invece che ogni singolo Ritz vector converga a uno specifico autovettore, soprattutto in presenza di autovalori ravvicinati.

L'ottimalità si formalizza tramite il principio di Courant–Fischer.

Teorema 1 (Courant–Fischer). Sia $A \in \mathbb{R}^{n \times n}$ simmetrica e $\mathcal{S} \subseteq \mathbb{R}^n$ un sottospazio di dimensione $m < n$. Indicando con

$$\theta_1 \leq \theta_2 \leq \dots \leq \theta_m$$

gli autovalori della matrice proiettata $H = Q^T A Q$, essi soddisfano

$$\theta_1 = \min_{\substack{x \in \mathcal{S} \\ \|x\|=1}} x^T A x, \quad \theta_m = \max_{\substack{x \in \mathcal{S} \\ \|x\|=1}} x^T A x.$$

Più in generale, i Ritz values sono caratterizzati dalle relazioni variazionali

$$\theta_k = \min_{\substack{\mathcal{U} \subseteq \mathcal{S} \\ \dim(\mathcal{U})=k}} \max_{\substack{x \in \mathcal{U} \\ \|x\|=1}} x^T A x, \quad k = 1, \dots, m.$$

2.4 La scelta di $\mathcal{S}$ e i Sottospazi di Krylov

L'efficacia del metodo di Rayleigh–Ritz è strettamente subordinata alla capacità di $\mathcal{S}$ di approssimare un sottospazio invariante di A . Se il sottospazio non contiene direzioni spettrali significative, le approssimazioni di Ritz possono risultare povere o convergere molto lentamente.

Il problema computazionale si sposta dunque sulla scelta del sottospazio $\mathcal{S}$. In assenza di informazioni *a priori*, la costruzione più efficiente prevede di generare $\mathcal{S}$ mediante l'applicazione iterativa dell'operatore A a un vettore iniziale v . Si introducono così i **sottospazi di Krylov**: la loro integrazione nel framework di Rayleigh–Ritz costituisce il fondamento del metodo di Lanczos. Tale scelta deriva da proprietà di ottimalità polinomiale: i sottospazi di Krylov sono strutturati in modo da "estrarre" con massima velocità gli autovalori estremi dello spettro, minimizzando progressivamente la norma del residuo $\|R\|_2$ e accelerando la convergenza verso la condizione di invarianza.

Tabella 1: Schema del metodo di Rayleigh–Ritz.

Passo	Operazione	Costo
1	Ortonormalizzare le colonne di S per ottenere Q ($n \times m$).	$m(m+1)n$
2	Calcolare AQ tramite m prodotti matrice–vettore.	m matvec
3	Formare $H = Q^T(AQ) \in \mathbb{R}^{m \times m}$.	$\frac{1}{2}m(m+1)n$
4	Calcolare le $p \leq m$ coppie di interesse di H : $Hg_i = \theta_i g_i$.	$\approx m^3$
5	Se richiesti, formare i Ritz vectors $y_i = Qg_i$.	$p m n$
6	Calcolare i residui $r_i = Ay_i - \theta_i y_i$ e le norme $\ r_i\ $. Ogni intervallo $[\theta_i - \ r_i\ , \theta_i + \ r_i\]$ contiene un autovalore di A .	$p(m+2)n$

3 Sottospazi di Krylov

3.1 Definizione e legame polinomiale

Sia $A \in \mathbb{R}^{n \times n}$ una matrice reale simmetrica e sia $v \in \mathbb{R}^n$ un vettore non nullo. Il sottospazio di Krylov di ordine m generato da A e v è definito come lo spazio generato dalle prime m iterazioni di A su v :

$$\mathcal{K}_m(A, v) = \text{span}\{v, Av, A^2v, \dots, A^{m-1}v\}.$$

Ogni elemento $w \in \mathcal{K}_m(A, v)$ può essere espresso come combinazione lineare dei vettori di base:

$$w = \sum_{j=0}^{m-1} \alpha_j A^j v = \left(\sum_{j=0}^{m-1} \alpha_j A^j \right) v.$$

Questo legame definisce in modo naturale un'applicazione lineare $\psi_v : \mathbb{P}_{m-1} \rightarrow \mathcal{K}_m(A, v)$ definita dall'azione:

$$\psi_v(p) = p(A)v$$

dove $p(z) = \sum_{j=0}^{m-1} \alpha_j z^j \in \mathbb{P}_{m-1}$.

Per costruzione, la mappa ψ_v è suriettiva. Inoltre il suo nucleo

$$\ker(\psi_v) = \{p \in \mathbb{P}_{m-1} : p(A)v = 0\}$$

è banale se e solo se $m \leq d$, dove d è il grado del polinomio minimo di v rispetto ad A . In tal caso, nessun polinomio non nullo di grado inferiore a m può annullare v , garantendo l'indipendenza lineare dell'insieme $\{v, Av, \dots, A^{m-1}v\}$. Quindi ψ_v è anche iniettiva, e pertanto è un isomorfismo canonico.

Poiché $\mathbb{P}_{m-1}$ è un sottospazio vettoriale di $\mathbb{P}_m$, ne consegue che:

$$\mathcal{K}_m(A, v) \subseteq \mathcal{K}_{m+1}(A, v).$$

Questa struttura a catena garantisce che metodi proiettivi come quello di Rayleigh–Ritz operino come un'approssimazione interna migliorabile: espandendo la dimensione dello spazio, l'insieme dei candidati per l'approssimazione cresce monotonamente. La catena di inclusioni stretta si arresta esattamente al passo $m = d$. In quel punto, $\ker(\psi_v)$ diventa non banale per lo spazio $\mathbb{P}_d$, il che implica che $A^d v$ è combinazione lineare delle potenze precedenti. Di conseguenza, $\mathcal{K}_d(A, v) = \mathcal{K}_{d+1}(A, v)$ e lo spazio diventa un sottospazio A -invariante, garantendo in aritmetica esatta la convergenza dei metodi iterativi.

3.2 Interpretazione spettrale e ottimalità polinomiale

Per chiarire l'efficacia dei sottospazi di Krylov nell'approssimazione degli autovalori estremi, è necessario superare l'analogia elementare con il metodo delle potenze. Sebbene l'applicazione di A^k amplifichi la componente dell'autovettore dominante, il metodo di Rayleigh–Ritz su $\mathcal{K}_m$ effettua una ricerca ottimale nell'intero spazio polinomiale.

Sia θ_1 il massimo Ritz value su $\mathcal{K}_m$. L'errore rispetto al vero autovalore massimo λ_1 è governato dalla capacità di un polinomio di isolare λ_1 dal resto dello spettro. Formalmente, si risolve un problema di min-max:

$$\frac{\lambda_1 - \theta_1}{\lambda_1 - \lambda_n} \leq \min_{p \in \mathbb{P}_{m-1}, p(\lambda_1)=1} \max_{j=2, \dots, n} |p(\lambda_j)|. \quad (5)$$

La soluzione di tale problema è legata ai **polinomi di Chebyshev**, i quali esibiscono una crescita esponenziale al di fuori dell'intervallo $[\lambda_n, \lambda_2]$. Questa "ottimalità polinomiale" garantisce che i Ritz values convergano agli estremi dello spettro con una velocità superiore a quella del metodo delle potenze, poiché il processo costruisce un filtro che minimizza l'influenza delle componenti spettrali non desiderate. Tale ottimalità polinomiale, qui discussa in termini qualitativi, verrà formalizzata matematicamente attraverso i bound di Kaniel-Saad nella Sezione 5.3.

3.3 Rayleigh–Ritz applicato ai sottospazi di Krylov

La combinazione del framework di Rayleigh–Ritz con la struttura di Krylov conduce a una semplificazione fondamentale per matrici simmetriche. Sia $Q_m \in \mathbb{R}^{n \times m}$ la matrice le cui colonne

costituiscono una base ortonormale di $\mathcal{K}_m(A, v)$. La matrice di Rayleigh $H_m = Q_m^T A Q_m$ assume in questo contesto una struttura **tridiagonale simmetrica**.

Tale proprietà distingue nettamente il caso simmetrico dalla teoria generale:

- **Algoritmo di Arnoldi:** In assenza di simmetria, H_m è una matrice di Hessenberg superiore e l'ortogonalizzazione di ogni nuovo vettore richiede il confronto con tutti i vettori precedenti (ortogonalizzazione completa).
- **Metodo di Lanczos:** La simmetria di A implica che ogni nuovo vettore della base può essere ortogonalizzato rispetto ai soli due vettori precedenti. Questa **ricorrenza a tre termini** riduce l'onere computazionale e di memoria, rendendo il metodo di Lanczos lo strumento d'elezione per problemi spettrali di grandi dimensioni.

4 L'algoritmo di Lanczos

4.1 Dalla proiezione di Rayleigh–Ritz alla costruzione di una base

L'obiettivo è estrarre approssimazioni ottimali degli autovalori estremi di una matrice simmetrica A lavorando su un sottospazio di dimensione ridotta $k \ll n$.

Il primo passo consiste nel determinare una base ortonormale $\{q_1, q_2, \dots, q_k\}$ per $\mathcal{K}_k(A, q_1)$. Invece di ortonormalizzare ex-post la matrice di Krylov $K_k = [q_1, Aq_1, \dots, A^{k-1}q_1]$, che risulta notoriamente mal condizionata, l'algoritmo di Lanczos costruisce la base iterativamente.

4.2 Ricorrenza a tre termini

Il cuore dell'algoritmo risiede nella semplificazione del processo di Arnoldi quando applicato a matrici simmetriche. Per una matrice generica, l'ortogonalizzazione di Gram–Schmidt richiede il confronto del nuovo vettore con tutti i precedenti ($O(k \cdot n)$). Tuttavia, se $A = A^T$, la matrice di proiezione $T_k = Q_k^T A Q_k$ assume una struttura **simmetrica tridiagonale**.

Formalmente, i vettori della base soddisfano una **ricorrenza a tre termini**:

$$t_{k+1,k} q_{k+1} = r_k, \quad \text{con } r_k = (A - t_{k,k}) q_k - t_{k-1,k} q_{k-1} \quad (6)$$

dove i coefficienti sono definiti come:

- $t_{k,k} = q_k^T A q_k$ (elemento diagonale)
- $t_{k+1,k} = \|r_k\|_2$ (elemento fuori diagonale e fattore di normalizzazione)

Questa implica che il nuovo vettore q_{k+1} è ortogonale per costruzione non solo a q_k e q_{k-1} , ma a tutti i vettori precedenti $q_1, \dots, q_{k-2}$, riducendo drasticamente il costo computazionale a un singolo prodotto matrice–vettore per iterazione.

4.3 La Decomposizione di Lanczos

Al passo k , la relazione fondamentale che lega la matrice A alla base di Lanczos Q_k e alla matrice tridiagonale T_k è espressa dalla **decomposizione di Lanczos**:

$$A Q_k = Q_k T_k + t_{k+1,k} q_{k+1} e_k^T \quad (7)$$

dove $Q_k = [q_1, q_2, \dots, q_k]$ è a colonne ortonormali e $T_k \in \mathbb{R}^{k \times k}$ è data da:

$$T_k = \begin{bmatrix} t_{1,1} & t_{1,2} & & & \\ t_{2,1} & t_{2,2} & \ddots & & \\ & \ddots & \ddots & \ddots & \\ & & & t_{k-1,k-1} & t_{k-1,k} \\ & & & t_{k,k-1} & t_{k,k} \end{bmatrix}.$$

In questa base, la proiezione dell'operatore A sul sottospazio di Krylov è rappresentata esattamente dalla matrice T_k , ovvero $T_k = Q_k^T A Q_k$. Se ad un certo passo k si verifica $t_k + 1, k=0$, l'algoritmo raggiunge una terminazione precoce (early termination). In tale circostanza, spesso definita happy breakdown, il metodo ha individuato un sottospazio invariante esatto e gli autovalori di T_k appartengono allo spettro di A .

4.4 Coppie di Ritz

Le approssimazioni cercate sono costituite dalle coppie di Ritz (θ_i, y_i) , dove i Ritz values θ_i sono gli autovalori della matrice ridotta T_k e il loro calcolo ha un costo computazionale trascurabile rispetto ai prodotti matrice-vettore, mentre i Ritz vectors y_i sono ottenuti riportando gli autovettori s_i di T_k nello spazio originale tramite la base di Lanczos: $y_i = Q_k s_i$. La qualità dell'approssimazione può essere monitorata tramite la norma del residuo $\|Ay_i - y_i\theta_i\|_2$, che nel metodo di Lanczos è calcolabile senza formare esplicitamente y_i :

$$\|Ay_i - y_i\theta_i\|_2 = t_{k+1,k} |e_k^T s_i| \quad (8)$$

dove $e_k^T s_i$ è l'ultima componente dell'autovettore di T_k .

Algorithm 1 Lanczos

Lo schema operativo è il seguente:

1. Scegli un vettore iniziale q_1 , imposta $q_1 = b/\|b\|_2$ e $q_0 = 0$.
 2. Per $k = 1, 2, \dots, m$:
 - a. Calcola $v = Aq_k$.
 - b. Calcola il coefficiente diagonale: $t_{k,k} = q_k^T v$.
 - c. Aggiorna il residuo: $v = v - t_{k,k} q_k - t_{k-1,k} q_{k-1}$ (con $t_{0,1} = 0$).
 - d. Calcola il coefficiente fuori diagonale: $t_{k+1,k} = \|v\|_2$.
 - e. Se $t_{k+1,k} < \text{tol}$ stop (breakdown).
 - f. Definisci il prossimo vettore: $q_{k+1} = v/t_{k+1,k}$.
 3. Forma T_k e calcola le Ritz pairs di interesse.
-

5 Accuratezza delle approssimazioni nel metodo di Lanczos

In questo capitolo si analizza l'accuratezza delle approssimazioni agli autovalori e agli autovettori prodotte dal metodo di Lanczos.

5.1 Residui e qualità delle coppie di Ritz

Sia (θ, y) una *coppia di Ritz* al passo m , con $y = Q_m g$ e (θ, g) autocoppia della matrice tridiagonale T_m , ovvero tale che $T_m g = \theta g$ con $\|g\|_2 = 1$. Il vettore residuo

$$r_m = Ay - \theta y \quad (9)$$

fornisce una misura diretta della qualità dell'approssimazione.

La struttura della base di Krylov e la relazione di ricorrenza di Lanczos permettono di stimare la norma del residuo senza dover calcolare esplicitamente il Ritz vector y :

$$\begin{aligned}
\|r_m\|_2 &= \|AQ_m g - \theta Q_m g\|_2 \\
&= \|(AQ_m - Q_m T_m)g\|_2 && \text{(poiché } T_m g = \theta g) \\
&= \|(\beta_m v_{m+1} e_m^T)g\|_2 && \text{(dalla relazione } AQ_m = Q_m T_m + \beta_m v_{m+1} e_m^T) \\
&= |\beta_m| \cdot \|v_{m+1}\|_2 \cdot |e_m^T g| \\
&= |\beta_m| \cdot |g_m| && \text{(essendo } \|v_{m+1}\|_2 = 1 \text{ e } g_m \text{ l'ultima componente di } g)
\end{aligned}$$

Si ottiene quindi l'importante identità $\|r_m\|_2 = |\beta_m g_m|$. Questo risultato spiega un fenomeno fondamentale: un Ritz value θ può risultare estremamente accurato anche in presenza di un parametro di accoppiamento β_m elevato, purché la componente di coda dell'autovettore di T_m (ovvero g_m) sia sufficientemente piccola. Tale quantità è monitorabile a costo computazionale nullo durante l'iterazione, fornendo un criterio di arresto efficiente e rigoroso.

5.2 Accuratezza degli autovettori: il teorema di Davis–Kahan

L'analisi del residuo vista poc'anzi non dice nulla sulla qualità dei Ritz *vectors*. Le due nozioni sono legate, ma non equivalenti: è possibile che θ sia un'ottima approssimazione di λ_i mentre il corrispondente Ritz vector y sia ancora lontano dall'autovettore esatto z_i . Sebbene la dimostrazione originale di Davis-Kahan sia estremamente sottile in quanto estesa alla distanza tra sottospazi di dimensione arbitraria, è possibile derivarne una versione semplificata per il caso rank-1 (vettoriale) tramite l'espansione spettrale.

Teorema 2 (Davis–Kahan, caso rank-1). *Sia $A \in \mathbb{R}^{n \times n}$ simmetrica con autovalori $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ e autovettori ortonormali $z_1, \dots, z_n$. Sia (θ_i, y_i) una Ritz pair al passo m , con residuo $r_i = Ay_i - \theta_i y_i$. Allora*

$$\sin \angle(z_i, y_i) \leq \frac{\|r_i\|_2}{\min_{j \neq i} |\theta_i - \lambda_j|}.$$

Dim. Si consideri l'espansione del Ritz vector y_i nella base ortonormale degli autovettori $\{z_j\}_{j=1}^n$ di A :

$$y_i = \sum_{j=1}^n c_j z_j, \quad \text{con} \quad \sum_{j=1}^n c_j^2 = \|y_i\|_2^2 = 1. \quad (10)$$

Sostituendo tale espressione nella definizione di residuo $r_i = (A - \theta_i I)y_i$, si ottiene $r_i = \sum_j c_j (\lambda_j - \theta_i) z_j$. Grazie all'ortogonalità della base, risulta:

$$\|r_i\|_2^2 = \sum_{j=1}^n c_j^2 (\lambda_j - \theta_i)^2 \geq \sum_{j \neq i} c_j^2 (\lambda_j - \theta_i)^2. \quad (11)$$

Introducendo il gap spettrale $\delta_i = \min_{j \neq i} |\lambda_j - \theta_i|$, possiamo scrivere:

$$\|r_i\|_2^2 \geq \delta_i^2 \sum_{j \neq i} c_j^2. \quad (12)$$

Osserviamo che la componente di y_i lungo l'autovettore cercato z_i è data dal coefficiente $c_i = \langle y_i, z_i \rangle = \cos \angle(z_i, y_i)$. Poiché il vettore y_i ha norma unitaria si ha:

$$\sum_{j \neq i} c_j^2 = 1 - c_i^2 = 1 - \cos^2 \angle(z_i, y_i) = \sin^2 \angle(z_i, y_i). \quad (13)$$

Sostituendo quest'ultima relazione nella disuguaglianza precedente e prendendo la radice quadrata, si ottiene la tesi:

$$\|r_i\|_2 \geq \delta_i \sin \angle(z_i, y_i). \quad (14)$$

□

Interpretazione. Il denominatore $\min_{j \neq i} |\theta_i - \lambda_j|$ è la distanza del Ritz value θ_i dal resto dello spettro di A : esso approssima il gap spettrale $\delta_i = \min_{j \neq i} |\lambda_i - \lambda_j|$ non appena $\theta_i \approx \lambda_i$. La stima evidenzia due fenomeni distinti:

- i. **Residuo piccolo non implica autovettore accurato.** Se δ_i è piccolo (autovalore in un cluster), anche un residuo $\|r_i\|_2 \ll 1$ può essere compatibile con $\sin \angle(z_i, y_i)$ dell'ordine dell'unità.
- ii. **Autovalori isolati: le due convergenze coincidono.** Quando $\delta_i \gg \|r_i\|_2$, il Ritz vector converge geometricamente insieme al Ritz value: la separazione spettrale agisce da amplificatore inverso dell'errore sull'autovettore.

Osservazione 3. Per autovalori multipli ($\delta_i = 0$) la stima è vuota. In quel caso si lavora con la proiezione sul sottospazio invariante associato all'autovalore multiplo, e il risultato corretto è una stima sull'angolo tra sottospazi (versione matriciale di Davis–Kahan, cfr. [1]).

5.3 Analisi a priori della convergenza: i bound di Kaniel–Paige–Saad

Si quantifica ora la velocità con cui i Ritz values approssimano gli autovalori estremi, in aritmetica esatta. Il risultato fondamentale si ottiene combinando il principio di Rayleigh–Ritz con la teoria dell'approssimazione polinomiale di Chebyshev applicata ai sottospazi di Krylov.

Il bound di Saad per l'autovalore minimo

Teorema 4 (Kaniel–Paige–Saad). *Sia $A \in \mathbb{R}^{n \times n}$ simmetrica con $\lambda_1 < \lambda_2 \leq \dots \leq \lambda_n$, e sia $\theta_1^{(m)}$ il minimo Ritz value estratto da $\mathcal{K}_m(A, v_1)$. Allora*

$$0 \leq \theta_1^{(m)} - \lambda_1 \leq (\lambda_n - \lambda_1) \left[\frac{\tan \angle(v_1, z_1)}{T_{m-1}(1 + 2\gamma_1)} \right]^2,$$

dove:

- z_1 è l'autovettore normalizzato di A associato a λ_1 ;
- T_{m-1} è il polinomio di Chebyshev di prima specie di grado $m-1$, valutato in $1 + 2\gamma_1$;
- $\gamma_1 = \frac{\lambda_2 - \lambda_1}{\lambda_n - \lambda_2}$ è il gap ratio relativo a λ_1 .

Crescita esponenziale di T_{m-1} e tasso di convergenza. Per $x > 1$, il polinomio di Chebyshev soddisfa $T_{m-1}(x) = \cosh((m-1) \operatorname{arccosh}(x)) \geq \frac{1}{2}(x + \sqrt{x^2 - 1})^{m-1}$. Ponendo $x = 1 + 2\gamma_1$ e notando che

$$x + \sqrt{x^2 - 1} = 1 + 2\gamma_1 + 2\sqrt{\gamma_1(1 + \gamma_1)} = \left(\frac{1 + \sqrt{\gamma_1/(1 + \gamma_1)}}{1 - \sqrt{\gamma_1/(1 + \gamma_1)}} \right) \cdot \frac{1}{\rho},$$

si ricava che il bound decade almeno come $\rho^{2(m-1)}$ con

$$\rho = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}, \quad \kappa = \frac{\lambda_n - \lambda_1}{\lambda_2 - \lambda_1} = 1 + \frac{1}{\gamma_1}.$$

Questa è la forma semplificata riportata in letteratura, che si scrive usualmente come

$$\theta_1^{(m)} - \lambda_1 \leq C (\lambda_n - \lambda_1) \rho^{2m}, \quad C = \tan^2 \angle(v_1, z_1).$$

Il parametro κ misura l'isolamento spettrale di λ_1 : più grande è il gap $\lambda_2 - \lambda_1$ rispetto allo spread $\lambda_n - \lambda_1$, più grande è κ , più piccolo è ρ e più rapida è la convergenza.

Analisi dei fattori di convergenza

Il bound isola tre fattori indipendenti che governano la velocità di convergenza di Lanczos:

1. **Geometria del vettore iniziale.** Se v_1 è quasi ortogonale a z_1 , l'angolo si avvicina a $\pi/2$ e la tangente diverge, richiedendo molte più iterazioni per estrarre la componente lungo z_1 . Nella pratica computazionale, l'impiego di un vettore iniziale casuale rende estremamente improbabile l'ortogonalità stretta con z_1 .
2. **Efficacia del filtro polinomiale** (T_{m-1}). Poiché $T_{m-1}(1 + 2\gamma_1)$ cresce esponenzialmente in m , il bound decade esponenzialmente: questo spiega perché Lanczos sia drasticamente più veloce del metodo delle potenze, il cui errore scala come $(\lambda_2/\lambda_1)^m$.
3. **Separazione spettrale** (γ_1). Se $\lambda_1 \approx \lambda_2$ (small gap), $\gamma_1 \approx 0$ e $1 + 2\gamma_1 \approx 1$: il polinomio di Chebyshev è valutato vicino alla propria regione di oscillazione $[-1, 1]$, dove la crescita è lenta. Il bound diventa poco informativo e la convergenza effettiva è lenta.

Estensione agli autovalori interni

Per un generico autovalore λ_i , il bound assume la forma

$$0 \leq \theta_i^{(m)} - \lambda_i \leq (\lambda_n - \lambda_i) \left[\frac{\kappa_i \tan \angle(v_1, z_i)}{T_{m-i}(1 + 2\gamma_i)} \right]^2,$$

dove $\gamma_i = (\lambda_{i+1} - \lambda_i)/(\lambda_n - \lambda_{i+1})$ e κ_i è una costante che dipende dagli angoli tra v_1 e i primi $i - 1$ autovettori. Il grado del polinomio è ora $m - i$: per ottenere la stessa accuratezza su λ_i rispetto a λ_1 sono necessarie i iterazioni aggiuntive. Questo conferma matematicamente l'osservazione sperimentale per cui gli autovalori più interni convergono più lentamente: hanno meno gradi di libertà polinomiali a disposizione e, in generale, un gap ratio γ_i meno favorevole.

Il “muro” dell'aritmetica finita

È cruciale sottolineare che i bound di Kaniel–Paige–Saad sono validi finché la base di Lanczos rimane ortonormale ($Q_m^T Q_m = I$). Come analizzato nel capitolo successivo, il teorema di Paige dimostra che non appena $\theta_i^{(m)}$ soddisfa il bound di Saad e converge a λ_i , l'ortogonalità globale collassa. Pertanto, i bound a priori descrivono correttamente la fase di *discesa* dell'errore, ma non possono prevedere la comparsa dei *ghost eigenvalues* tipici dell'aritmetica floating-point, fenomeno trattato nella Sezione 6.1.

6 Aspetti numerici del metodo di Lanczos

Finora si è assunta aritmetica esatta: in quel contesto la ricorrenza a tre termini produce una base ortonormale e T_m è esattamente la matrice di Rayleigh. In aritmetica finita entrambe le proprietà vengono meno, con conseguenze sul comportamento dell'algoritmo.

6.1 Perdita di ortogonalità in aritmetica finita

In aritmetica finita, gli errori di arrotondamento accumulati durante le iterazioni compromettono progressivamente l'ortogonalità dei vettori di Lanczos. Sebbene la ricorrenza a tre termini mantenga una buona ortogonalità locale, essa non garantisce l'ortogonalità globale rispetto a tutti i vettori precedentemente costruiti.

Di conseguenza, il prodotto scalare $v_i^T v_j$, che in aritmetica esatta sarebbe nullo per $i \neq j$, assume valori non trascurabili al crescere del numero di iterazioni. Questo fenomeno è intrinseco all'aritmetica in virgola mobile e non dipende da una scorretta implementazione dell'algoritmo.

6.2 Quantificazione della perdita di ortogonalità

In aritmetica finita, la qualità della base di Lanczos Q_m degrada progressivamente a causa degli errori di arrotondamento. Per gestire questo fenomeno, è necessario dapprima definire come misurarlo.

La deviazione della matrice di Gram $Q_m^T Q_m$ dall'identità può essere quantificata tramite diverse norme. Una scelta comune è la **norma di Frobenius** ($\mathcal{E}_F = \|Q_m^T Q_m - I\|_F$), che permette di pesare l'errore globale su ogni coppia di vettori ed è computazionalmente semplice.

Tuttavia, l'analisi teorica della stabilità privilegia la **norma spettrale** $\|\cdot\|_2$. Il motivo di tale preferenza risiede nel legame diretto tra la norma spettrale e la perdita di indipendenza lineare della base: la norma $\|Q_m^T Q_m - I\|_2$ è legata al declino del valore singolare minimo $\sigma_{\min}(Q_m)$ verso lo zero. Quando tale norma di deviazione si avvicina all'unità, il sottospazio di Krylov “collassa” numericamente. Secondo il Teorema di Paige, questo fenomeno è innescato dalla convergenza di una coppia di Ritz: non appena un autovalore approssimato raggiunge la precisione macchina, la base diventa linearmente dipendente, causando la comparsa dei ghost eigenvalues, che non portano nuova informazione spettrale ma riflettono la riemersione di direzioni già convergenti.

Negli esperimenti numerici (cfr. Sezione 7.7), l'adozione di una norma matriciale globale ad ogni passo risulterebbe troppo onerosa. Si adotta quindi una metrica più operativa basata sul **massimo prodotto scalare assoluto** tra i vettori della base:

$$\delta_m = \max_{i < m} |q_i^T q_m| \quad (15)$$

Tale parametro è un sostituto operativo e computazionalmente efficiente per monitorare la tenuta della base. Secondo i criteri di Parlett e Scott, non è necessario mantenere l'ortogonalità a precisione di macchina (ϵ_{mach}); è sufficiente garantire la **semi-ortogonalità**, ovvero che $\delta_m \leq \sqrt{\epsilon_{mach}}$. Finché questo limite è rispettato, i Ritz values mantengono la loro accuratezza e non compaiono duplicati spuri.

6.2.1 Strategie di re-ortogonalizzazione

Per preservare la semi-ortogonalità, si possono adottare due strategie principali:

1. **Full Re-orthogonalization (FRO):** È la soluzione più robusta ma costosa ($O(m^2 n)$). Consiste nel ri-ortogonalizzare il nuovo vettore rispetto a *tutta* la base accumulata ad ogni passo. Sebbene garantisca un'ortogonalità prossima a ϵ_{mach} , il costo computazionale e di memoria cresce quadraticamente con le iterazioni.
2. **Selective Orthogonalization (SO):** Rappresenta il compromesso ottimale basato sui risultati di Paige. Il punto chiave è che la perdita di ortogonalità non è casuale, ma avviene sistematicamente lungo le direzioni dei **Ritz vectors già convergenti**. Invece di pulire il vettore rispetto a tutta la base, la SO interviene selettivamente solo quando δ_m supera la soglia $\sqrt{\epsilon_{mach}}$, ortogonalizzando il residuo solo rispetto alle coppie di Ritz che segnalano convergenza. Questo approccio permette di mantenere la qualità spettrale della FRO con un costo computazionale drasticamente ridotto.

Se si cercano solo gli autovalori estremi, il metodo funziona bene anche senza re-ortogonalizzazione: tali autovalori convergono in poche iterazioni e sono poco sensibili alla perdita di ortogonalità. Se invece si vuole approssimare uno spettro più ampio o ottenere autovettori affidabili, i ghost eigenvalues diventano un problema reale e occorre introdurre qualche forma di re-ortogonalizzazione.

6.3 La trasformazione shift-and-invert

Una strategia classica per approssimare autovalori interni consiste nell'applicare una **trasformazione shift-and-invert**. Data una matrice A e un parametro σ (lo shift), si considera il

problema agli autovalori per la matrice trasformata

$$B = (A - \sigma I)^{-1}. \quad (16)$$

Se (λ, u) è una coppia autovalore-autovettore di A , allora (μ, u) è una coppia autovalore-autovettore di B , dove

$$\mu = \frac{1}{\lambda - \sigma}. \quad (17)$$

Questa trasformazione inverte e trasla lo spettro: gli autovalori di A vicini a σ corrispondono ad autovalori di B con modulo elevato, diventando quindi estremi del nuovo spettro. Applicando il metodo di Lanczos a B , si ottiene convergenza rapida verso gli autovalori di interesse.

6.3.1 Aspetti implementativi

L'applicazione dell'operatore $B = (A - \sigma I)^{-1}$ a un vettore di Lanczos si realizza attraverso la risoluzione del sistema lineare

$$(A - \sigma I)w = v. \quad (18)$$

Date le dimensioni elevate e la sparsità della matrice A , tale risoluzione viene affidata a metodi iterativi interni come MINRES. Questa scelta è dettata dalla necessità di preservare la struttura sparsa del problema: l'impiego di metodi diretti basati su fattorizzazioni esatte risulterebbe infatti inefficiente a causa del fenomeno del fill-in, che comporterebbe un'occupazione di memoria e un costo computazionale proibitivi.

In questo scenario, il costo di ogni iterazione esterna di Lanczos è proporzionale al numero di iterazioni richieste dal metodo interno per raggiungere la convergenza. Sebbene il costo per singolo passo sia superiore rispetto al Lanczos standard, l'efficacia dello *shift-and-invert* risiede nella drastica riduzione del numero totale di iterazioni esterne m , ottenuta grazie alla migliore separazione spettrale. Per accelerare la convergenza del metodo interno, è prassi comune integrare tecniche di preconditionamento, quali fattorizzazioni incomplete (*ILU* o *IC*).

Per quanto riguarda lo *shift* σ , la strategia ottimale prevede il suo posizionamento in prossimità dei valori target. In assenza di informazioni *a priori*, si possono utilizzare i risultati di pochi passi di Lanczos standard per identificare le regioni di interesse dello spettro e fissare di conseguenza il parametro σ .

E' opportuno osservare infine che l'introduzione di un inner solver modifica parzialmente l'algoritmo. A ogni iterazione esterna k , la risoluzione inesatta del sistema lineare $(A - \sigma I)w_k = q_k$ introduce un vettore residuo interno $\eta_k = (A - \sigma I)w_k - q_k$. Invertendo la relazione, il vettore effettivamente calcolato risulta essere $w_k = Bq_k - B\eta_k$. Definendo la matrice degli errori accumulati $F_m = -B[\eta_1, \eta_2, \dots, \eta_m]$, la decomposizione di Lanczos standard perde la sua esattezza e subisce una perturbazione:

$$BQ_m = Q_m T_m + t_{m+1,m} q_{m+1} e_m^T + F_m$$

. Di conseguenza, il processo di estrazione di Rayleigh-Ritz non opera più sul vero spazio $\mathcal{K}_m(B, q_1)$, ma su uno spazio perturbato dipendente dalla storia della convergenza interna. Affinché le garanzie teoriche sui Ritz values presentate nei capitoli precedenti non collassino, la norma della perturbazione $\|F_m\|_2$ deve essere rigorosamente limitata. Questo impone un vincolo computazionale stringente: la tolleranza di arresto del solver interno (MINRES) non può essere scelta arbitrariamente, ma deve essere mantenuta a un valore significativamente inferiore (es. $\tau_{inner} \approx 10^{-10}$) rispetto all'accuratezza target desiderata per le autocoppie esterne, pena la perdita di validità dell'ottimalità variazionale della proiezione.

Tabella 2: Confronto dei costi computazionali e di memoria.

Metodo	Setup	Costo per iter.	Memoria	# iter.
Lanczos standard	—	$O(\text{nnz}(A))$	$O(n \cdot m)$	$m \ll n$
Lanczos + full reorth	—	$O(\text{nnz}(A) + nm)$	$O(n \cdot m)$	$m \ll n$
Shift-and-invert	$O(\text{nnz}(A))^*$	$O(k \cdot \text{nnz}(A))$	$O(\text{nnz}(A) + nm)$	$m \ll n$
Metodo denso (QR)	—	$O(n^3)$	$O(n^2)$	—

Note: $\text{nnz}(A)$ indica il numero di elementi non nulli; k è il numero medio di iterazioni del solver interno; (*) il costo di setup riguarda la costruzione del preconditionatore.

7 Esperimenti numerici

Si presentano sei gruppi di esperimenti numerici, con l'ultimo suddiviso nelle due parti 6a e 6b. L'obiettivo è mettere in evidenza, in modo riproducibile, i principali fenomeni discussi nella parte teorica: convergenza preferenziale verso gli estremi dello spettro, efficacia della trasformazione shift-and-invert per gli autovalori interni, perdita di ortogonalità e ghost eigenvalues, effetto delle strategie di re-ortogonalizzazione e comportamento dei bound di Kaniel–Paige–Saad e Davis–Kahan.

7.1 Impostazione dei test

In tutti gli esperimenti si considera il problema

$$Ax = \lambda x,$$

con $A \in \mathbb{R}^{n \times n}$ reale e simmetrica. Il codice è scritto in Python e utilizza NumPy e SciPy. I problemi tridiagonali prodotti dal processo di Lanczos sono risolti con `scipy.linalg.eigh_tridiagonal`.

Sono impiegate tre varianti dell'algoritmo:

- **Lanczos standard:** ricorrenza a tre termini senza re-ortogonalizzazione;
- **Full Re-Orthogonalization (FRO):** doppia passata di Gram–Schmidt modificato rispetto a tutti i vettori della base già costruiti;
- **Selective Orthogonalization (SO):** strategia selettiva di tipo Parlett–Scott, con soglia $\nu = \sqrt{\varepsilon_{\text{mach}}}$ e re-ortogonalizzazione rispetto alle direzioni di Ritz selezionate.

Salvo diversa indicazione, l'errore su un autovalore target è misurato in forma normalizzata,

$$\varepsilon^{(m)} = \frac{|\theta^{(m)} - \lambda|}{\lambda_{\max} - \lambda_{\min}},$$

e si considera raggiunta la convergenza quando $\varepsilon^{(m)} < 10^{-8}$. Un eventuale lucky breakdown è rilevato quando il coefficiente di ricorrenza soddisfa $\beta_j \leq 10^{-14}$.

7.2 Esperimento 1: convergenza degli autovalori estremi vs. interni

Obiettivo. Confrontare la velocità con cui Lanczos standard approssima gli autovalori estremi e quelli interni su una matrice sparsa proveniente da una discretizzazione bidimensionale.

Tabella 3: Parametri degli esperimenti numerici.

Esp.	Matrice	n	Variante Lanczos	$m_{\max}$
1	Laplaciano 2D sparso, griglia 32×32	1024	Standard	80
2	Stesso Laplaciano 2D	1024	Standard + shift-and-invert	80
3	Matrice simmetrica con cluster spettrali	300	Standard	150
4	Stessa matrice dell'Esp. 3	300	Standard vs. FRO	60
5	Stessa matrice dell'Esp. 3	300	Standard vs. SO vs. FRO	60
6a	Matrice con autovalore isolato e cluster quasi degeneri	400	FRO (KPS)	110
6b	Stessa matrice dell'Esp. 6a	400	FRO (Davis–Kahan)	110

Setup numerico. Si considera il Laplaciano discreto 2D su una griglia 32×32 con condizioni di Dirichlet:

$$L_{2D} = L_{1D} \otimes I + I \otimes L_{1D}, \quad L_{1D} = \text{tridiag}(-1, 2, -1).$$

La matrice ha dimensione $n = 1024$ e $\text{nnz}(L_{2D}) = 4992$. Gli autovalori esatti sono disponibili analiticamente:

$$\lambda_{j,k} = \left(2 - 2 \cos \frac{j\pi}{33}\right) + \left(2 - 2 \cos \frac{k\pi}{33}\right), \quad j, k = 1, \dots, 32.$$

I target considerati sono

$$\lambda_{\min} = 0.0181123, \quad \lambda_{\max} = 7.9818877, \quad \lambda_{50} = 0.6349859, \quad \lambda_{200} = 2.1313064.$$

Il vettore iniziale è gaussiano, normalizzato, con seed 7, e si eseguono al più 80 iterazioni. Il tempo riportato sull'asse orizzontale della figura è il tempo CPU cumulativo misurato durante l'esecuzione.

Risultati. Gli autovalori estremi raggiungono la soglia 10^{-8} : $\lambda_{\min}$ al passo $m = 65$ e $\lambda_{\max}$ al passo $m = 72$. I due target interni non raggiungono invece la soglia entro $m_{\max} = 80$.

I valori dei gap ratio confermano la diversa difficoltà dei target:

Tabella 4: Gap ratio e convergenza osservata nell'Esperimento 1.

Target	gap	γ	ρ	convergenza
$\lambda_{\min}$	2.7086×10^{-2}	3.4128×10^{-3}	0.8898	$m = 65$
$\lambda_{\max}$	2.7086×10^{-2}	3.4128×10^{-3}	0.8898	$m = 72$
λ_{50}	1.5237×10^{-2}	2.0783×10^{-3}	0.9129	non conv.
λ_{200}	0	0	–	non conv.

Il caso di λ_{200} riflette la molteplicità presente nello spettro del Laplaciano 2D: il gap locale è nullo e il corrispondente parametro ρ non è definito nella forma scalare utilizzata per gli autovalori semplici.




Figura 1: Esperimento 1: errore normalizzato degli autovalori estremi e interni in funzione del tempo CPU cumulativo.

7.3 Esperimento 2: shift-and-invert per autovalori interni

Obiettivo. Verificare che la trasformazione shift-and-invert renda rapidamente accessibili gli autovalori interni che non convergono con Lanczos standard.

Setup numerico. Si usa lo stesso Laplaciano dell'Esperimento 1. Per

$$B_\sigma = (A - \sigma I)^{-1}$$

l'applicazione di B_σ a un vettore viene effettuata tramite una fattorizzazione LU sparsa di $A - \sigma I$, costruita una sola volta. I Ritz values μ della matrice trasformata sono riportati nello spettro originale mediante

$$\hat{\lambda} = \sigma + \frac{1}{\mu}.$$

Si utilizzano tre shift:

$$\sigma_{50} = \lambda_{50} - 10^{-4} = 0.6348859,$$

$$\sigma_{200} = \lambda_{200} - 10^{-4} = 2.1312064,$$

$$\sigma_{\text{far}} = \frac{\lambda_{50} + \lambda_{200}}{2} = 1.3831462.$$

Il vettore iniziale è lo stesso dell'Esperimento 1 e $m_{\text{max}} = 80$.

Risultati. Con uno shift vicino al target, entrambi gli autovalori interni raggiungono la tolleranza al passo $m = 3$. Con lo shift lontano, λ_{50} non converge entro 80 passi; l'errore normalizzato finale è circa 4.35×10^{-3} .

I tempi di fattorizzazione e delle singole solve vengono misurati dal codice, ma dipendono dall'hardware e dall'ambiente di esecuzione; per questo motivo non vengono utilizzati come valori numerici invarianti dell'esperimento.

Tabella 5: Convergenza shift-and-invert nell'Esperimento 2.

Configurazione	Target	Iterazione a tolleranza
$\sigma = \lambda_{50} - 10^{-4}$	λ_{50}	3
$\sigma = \lambda_{200} - 10^{-4}$	λ_{200}	3
$\sigma = \sigma_{\text{far}}$	λ_{50}	non conv. in 80




Figura 2: Esperimento 2: errore normalizzato dopo la trasformazione shift-and-invert per shift vicini e lontani dal target.

7.4 Esperimento 3: ghost eigenvalues e perdita di ortogonalità

Obiettivo. Studiare la comparsa dinamica dei ghost eigenvalues nel Lanczos standard e confrontare una classificazione che usa lo spettro esatto con una classificazione euristica basata esclusivamente sull'evoluzione dei Ritz values.

Setup numerico. Si considera una matrice

$$A = Q\Lambda Q^T \in \mathbb{R}^{300 \times 300},$$

con Q ortogonale ottenuta da una fattorizzazione QR di una matrice gaussiana con seed 42. Lo spettro è costruito come segue:

- cluster inferiore $\{0.10, 0.11, 0.12\}$;
- 10 autovalori uniformemente distribuiti in $[0.5, 2.0]$;
- cluster $\{4.90, 5.00, 5.01, 5.02\}$;
- autovalori rimanenti uniformemente distribuiti in $[6.0, 9.5]$.

Si eseguono $K = 150$ passi di Lanczos standard. La soglia utilizzata per la classificazione dei ghost è 10^{-4} .

Un Ritz value viene classificato come ghost rispetto allo spettro esatto quando più Ritz values convergono, entro la soglia fissata, verso lo stesso autovalore esatto; tutte le copie eccedenti quella più vicina sono conteggiate come ghost. In parallelo si usa un criterio euristico che confronta le radici di T_m e T_{m-1} senza accedere allo spettro esatto.

Risultati. Il primo ghost secondo il classificatore basato sullo spettro esatto compare al passo $k = 64$. Al passo finale $K = 150$ si osservano 31 ghost; il massimo transitorio osservato durante l'esecuzione è 32. Il classificatore euristico restituisce anch'esso 31 ghost al passo finale e un massimo di 32.

La perdita di ortogonalità misurata al passo finale tramite

$$\max_{i < j} |q_i^T q_j|$$

vale circa 1.61×10^{-1} .




Figura 3: Esperimento 3: evoluzione dei Ritz values e conteggio dei ghost con classificazione esatta ed euristica.

7.5 Esperimento 4: Lanczos standard vs. Full Re-Orthogonalization

Obiettivo. Quantificare l'effetto della perdita di ortogonalità sull'accuratezza dei Ritz values e confrontare Lanczos standard con la Full Re-Orthogonalization.

Setup numerico. Si usa la stessa matrice e lo stesso vettore iniziale dell'Esperimento 3, limitando il processo a $K = 60$ passi. L'ortogonalità è misurata tramite

$$\delta_j = \max_{i < j} |q_i^T q_j|,$$

mentre l'accuratezza di ogni Ritz value θ è misurata tramite la distanza dal più vicino autovalore esatto:

$$\min_i |\theta - \lambda_i|.$$

Risultati. Nel Lanczos standard la soglia $\sqrt{\varepsilon_{\text{mach}}} \approx 1.49 \times 10^{-8}$ viene superata al passo 40, secondo l'indicizzazione adottata nel codice. A $K = 60$ si ottiene

$$\delta_{\text{std}} \approx 3.118 \times 10^{-1}, \quad \delta_{\text{FRO}} \approx 6.74 \times 10^{-17}.$$

Gli errori dei Ritz values sono:

Tabella 6: Confronto Standard–FRO nell'Esperimento 4.

Variante	Ortogonalità finale	Errore Ritz medio	Errore Ritz massimo
Standard	3.118×10^{-1}	4.234×10^{-3}	1.120×10^{-1}
FRO	6.741×10^{-17}	2.002×10^{-3}	6.046×10^{-3}

La FRO mantiene quindi la base numericamente ortogonale e riduce in modo marcato soprattutto l'errore Ritz massimo.




Figura 4: Esperimento 4: perdita di ortogonalità e accuratezza dei Ritz values per Lanczos standard e FRO.

7.6 Esperimento 5: Selective Orthogonalization

Obiettivo. Confrontare Lanczos standard, Selective Orthogonalization e Full Re-Orthogonalization sulla stessa matrice dell'Esperimento 3.

Setup numerico. Si eseguono $K = 60$ passi con le tre varianti usando lo stesso vettore iniziale. Per la SO si usa la soglia

$$\nu = \sqrt{\varepsilon_{\text{mach}}} \approx 1.49 \times 10^{-8}.$$

Durante l'esecuzione il numero massimo di direzioni selezionate e mantenute dalla strategia SO è 17.

Risultati. La SO rimane semi-ortogonale per tutti i passi dell'esperimento. I risultati finali sono:

Tabella 7: Confronto tra Standard, SO e FRO nell'Esperimento 5.

Variante	Ortogonalità finale	Errore Ritz medio	Errore Ritz massimo
Standard	3.118×10^{-1}	4.234×10^{-3}	1.120×10^{-1}
SO	5.767×10^{-14}	2.002×10^{-3}	6.046×10^{-3}
FRO	6.741×10^{-17}	2.002×10^{-3}	6.046×10^{-3}

SO e FRO forniscono quindi, in questo test, errori Ritz praticamente coincidenti, mentre la SO interviene soltanto sulle direzioni selezionate.




Figura 5: Esperimento 5: confronto fra Lanczos standard, SO e FRO.

7.7 Esperimento 6a: bound di Kaniel–Paige–Saad

Obiettivo. Confrontare l'errore osservato sull'autovalore estremo isolato con il decadimento asintotico previsto dal bound di Kaniel–Paige–Saad.

Setup numerico. Si costruisce

$$A = Q\Lambda Q^T \in \mathbb{R}^{400 \times 400}$$

con seed 13 e spettro composto da:

- $\lambda_{\text{iso}} = 0.05$;
- 30 autovalori uniformemente distribuiti in $[1, 2]$;
- il cluster $\{4, 4 + 10^{-6}, 4 + 2 \cdot 10^{-6}\}$;
- gli autovalori rimanenti uniformemente distribuiti in $[6, 10]$.

La matrice ortogonale Q è ottenuta da una QR di una matrice gaussiana deterministica. Il vettore iniziale è costruito in modo da soddisfare

$$C = \tan^2 \angle(v_1, z_1) = 287,$$

che corrisponde a

$$\angle(v_1, z_1) \approx 86.6219^\circ.$$

Si eseguono $m_{\text{max}} = 110$ passi di Lanczos-FRO.

Per $\lambda_1 = 0.05$, $\lambda_2 = 1$ e $\lambda_n = 10$:

$$\gamma_1 = \frac{\lambda_2 - \lambda_1}{\lambda_n - \lambda_2} = 0.105556,$$

$$\kappa = \frac{\lambda_n - \lambda_1}{\lambda_2 - \lambda_1} = 10.473684, \quad \rho = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} = 0.527891.$$

Risultati. L'errore normalizzato sull'autovalore isolato scende sotto 10^{-8} al passo $m = 17$. La curva

$$C\rho^{2m}$$

rimane al di sopra dell'errore osservato per tutti i passi in cui il suo valore è superiore alla precisione di macchina.

Tabella 8: Parametri e risultato dell'Esperimento 6a.

γ_1	κ	ρ	C	angolo iniziale	convergenza
0.105556	10.473684	0.527891	287	86.6219°	$m = 17$




Figura 6: Esperimento 6a: errore normalizzato osservato e curva asintotica $C\rho^{2m}$.

7.8 Esperimento 6b: autovettori e teorema di Davis–Kahan

Obiettivo. Confrontare la convergenza dell’autovalore e dell’autovettore per un autovalore ben isolato e per un autovalore appartenente a un cluster quasi degenere.

Setup numerico. Si usa la stessa matrice, lo stesso vettore iniziale e la stessa Lanczos-FRO dell’Esperimento 6a. I due target sono

$$\lambda_{\text{iso}} = 0.05, \quad \lambda_c = 4.0.$$

Le separazioni spettrali sono

$$\delta_{\text{iso}} = 0.95, \quad \delta_c \approx 10^{-6}.$$

Per ogni passo si calcolano l’errore normalizzato sull’autovalore, $\sin \angle(z_i, y_i)$ e il bound

$$\frac{\|r_i\|_2}{\delta_i}.$$

La soglia utilizzata per dichiarare la convergenza dell’autovettore è

$$\sin \angle(z_i, y_i) < 10^{-10}.$$

Risultati. Per l’autovalore isolato, l’errore sull’autovalore scende sotto 10^{-8} al passo $m = 17$, mentre l’autovettore raggiunge la soglia 10^{-10} al passo $m = 37$. Al termine dei 110 passi:

$$\sin \angle(z_{\text{iso}}, y_{\text{iso}}) \approx 2.26 \times 10^{-15}.$$

Per il target nel cluster, l’autovalore raggiunge la soglia al passo $m = 51$, mentre l’autovettore non raggiunge 10^{-10} entro $m_{\text{max}} = 110$. Il valore finale è

$$\sin \angle(z_c, y_c) \approx 6.55 \times 10^{-10}.$$

La differenza tra i due casi mostra quantitativamente il ruolo del gap spettrale nel passaggio da un residuo piccolo a un autovettore accurato.

Tabella 9: Risultati Davis–Kahan nell’Esperimento 6b.

Target	δ	conv. autovalore	conv. autovettore	$\sin \angle$ finale
$\lambda_{\text{iso}} = 0.05$	0.95	$m = 17$	$m = 37$	2.26×10^{-15}
$\lambda_c = 4.0$	10^{-6}	$m = 51$	non conv. in 110	6.55×10^{-10}




Figura 7: Esperimento 6b: errore angolare e bound di Davis–Kahan per l’autovalore isolato e per il target nel cluster.

8 Discussione finale e conclusioni

Gli esperimenti numerici confermano, con configurazioni riproducibili, i principali meccanismi descritti nella parte teorica.

Convergenza agli estremi e difficoltà degli autovalori interni. Sul Laplaciano 2D 32×32 , Lanczos standard porta $\lambda_{\min}$ e $\lambda_{\max}$ sotto la soglia 10^{-8} rispettivamente in 65 e 72 passi, mentre λ_{50} e λ_{200} non convergono entro 80 iterazioni. Il comportamento è coerente con la diversa separazione spettrale dei target e con l’interpretazione polinomiale dei sottospazi di Krylov.

Shift-and-invert modifica efficacemente la geometria spettrale. Applicando $(A - \sigma I)^{-1}$ con uno shift posto a distanza 10^{-4} dal target, sia λ_{50} sia λ_{200} raggiungono la tolleranza in 3 passi. Uno shift lontano non produce invece convergenza per λ_{50} entro il budget di 80 iterazioni.

Perdita di ortogonalità e ghost eigenvalues. Nell’esperimento con spettro clusterizzato, il primo ghost viene rilevato al passo 64. Al passo 150 il classificatore basato sullo spettro esatto conta 31 ghost, con un massimo transitorio di 32; il criterio euristico termina anch’esso con 31 ghost. La perdita finale di ortogonalità del Lanczos standard raggiunge circa 1.61×10^{-1} .

La re-ortogonalizzazione controlla il degrado spettrale. A 60 passi il Lanczos standard presenta $\max_{i < j} |q_i^T q_j| \approx 3.12 \times 10^{-1}$ e un errore Ritz massimo di circa 1.12×10^{-1} . La FRO mantiene invece l’ortogonalità a circa 6.74×10^{-17} e riduce l’errore Ritz massimo a 6.05×10^{-3} . La SO raggiunge praticamente la stessa accuratezza Ritz della FRO, con ortogonalità finale 5.77×10^{-14} e senza superare la soglia di semi-ortogonalità $\sqrt{\varepsilon_{\text{mach}}}$.

Il bound KPS descrive correttamente il decadimento dell’errore estremo. Per $\lambda_{\text{iso}} = 0.05$, con $C = 287$, $\gamma_1 = 0.105556$ e $\rho = 0.527891$, la convergenza numerica avviene al passo 17. La curva asintotica $C\rho^{2m}$ rimane un upper bound dell’errore osservato fino al livello della precisione di macchina.

Un autovalore accurato non implica necessariamente un autovettore accurato. Nel test Davis–Kahan, il target isolato converge come autovalore al passo 17 e come autovettore

al passo 37. Per $\lambda_c = 4.0$, il Ritz value raggiunge la soglia al passo 51, ma l'autovettore non raggiunge 10^{-10} entro 110 passi e termina con $\sin \angle \approx 6.55 \times 10^{-10}$. La separazione spettrale, 0.95 nel primo caso e circa 10^{-6} nel secondo, spiega la differenza attraverso il denominatore del bound di Davis–Kahan.

Sintesi. La struttura di Krylov rende Lanczos particolarmente efficace per le componenti spettrali estreme; shift-and-invert permette di trasferire questa efficacia verso gli autovalori interni; FRO e SO contrastano gli effetti dell'aritmetica finita; infine, i test KPS e Davis–Kahan mostrano come la separazione spettrale governi rispettivamente la velocità di convergenza dei Ritz values e la qualità dei Ritz vectors.

Riferimenti bibliografici

- [1] G. H. Golub and C. F. Van Loan, *Matrix Computations*, 4th ed., Johns Hopkins University Press, 2013.
- [2] Y. Saad, *Numerical Methods for Large Eigenvalue Problems*, 2nd ed., SIAM, 2011.
- [3] B. N. Parlett, *The Symmetric Eigenvalue Problem*, SIAM, 1998.
- [4] L. N. Trefethen and D. Bau, *Numerical Linear Algebra*, SIAM, 1997.